تمرين دوم درس بازيابی اطلاعات

تشخیص ژانر فیلم با استفاده از Storyline فیلم

سارا زاهدی موحد شماره دانشجویی: 98170849

در این تمرین از دیتای سایت imdb استفاده کردم تا بتوانم با گرفتن storyline، ژانر فیلم را با دقت نسبتا خوبی تشخیص دهم.

برای این کار، اطلاعات چند فیلم (حدود 2000 فیلم) را با استفاده از کرالری که نوشتم و در فایل تمرین موجود است، جمع آوری کردم. اطلاعات فیلم شامل ژانر و storyline هر فیلم میشود. این اطلاعات را در یک فایل با نام dataset.json نگهداری کردم.

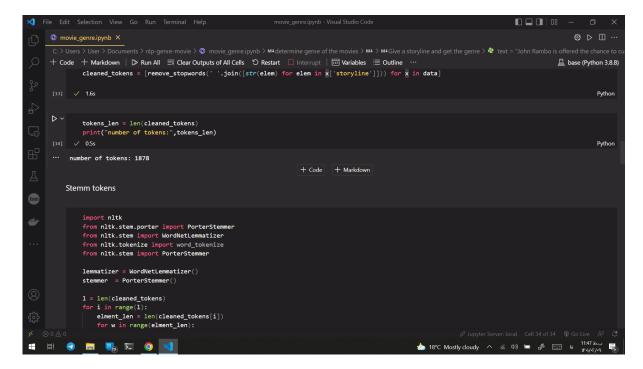
کرال سایت و پیدا کردن لینک های فیلم های لینک (برای رجکس url):

```
+ Code + Markdown | ▷ Run All = Clear Outputs of All Cells | = Outline ...
                                                                                                                                                                                    Select Kernel
          pre_url = 'https://www.imdb.com/'
for movie in soup.find_all('a', ('href': re.compile(r'title'))):
    movie = pre_url + movie['href']
    urls.append(movie)
           urls.remove(urls[0])
          size = len(movies_name)
rgx = "^https:\/\/www\.imdb\.com\/\/title\/tt\d+\/$"
          i = len(urls)
                  in range(1, size*2, 2):
re.search(rgx, urls[m]):
  movies_link.append(urls[m])
          movies_link
     ['https://www.imdb.com//title/tt0109506/',
       https://www.imdb.com//title/tt0103873/',
       'https://www.imdb.com//title/tt0082010/',
       'https://www.imdb.com//title/tt0075005/'
       https://www.imdb.com//title/tt0073582/'
       https://www.imdb.com//title/tt0070917/',
         📋 🌓 도 🧿 🔀
                                                                                                                              11:39 الله 18°C Mostly cloudy 🔨 🧷 (4)) 🖼 🔑 🚃 اله 11:39
```

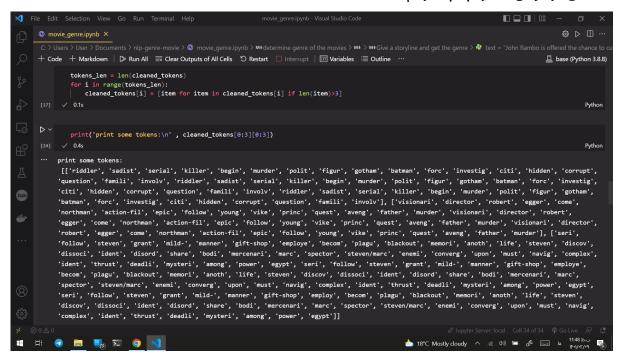
پیدا کردن و ریختن استوری لاین و ژانر هر فیلم در فایل json:

وقتی فایل جیسون را ساختم، به تحلیل داده های آن پرداختم. تعداد جملات و کلمات استوری لاین ها جمعا به شکل زیر است:

تعداد توکن ها مجموعا در زیر آمده است:



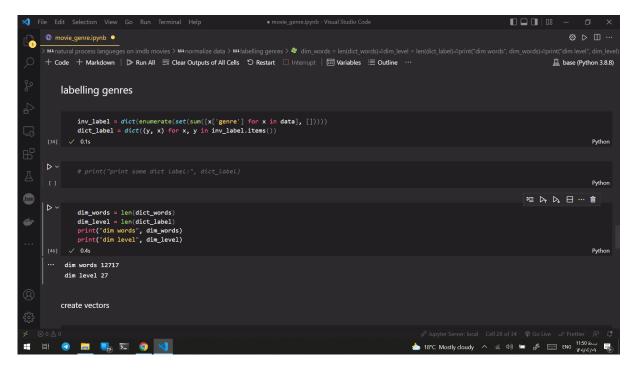
تعدادی از توکن ها را چاپ کردم:



در مرحله بعد، اطلاعات را نرمالایز و توکنایز کردم. سپس به هر واژه و هر ژانر، یک لیبل اختصاص دادم.

```
$ ▷ □ …
    base (Python 3.8.8)
   import nltk
from nltk.stem.porter import PorterStemmer
from nltk.stem import WordNetLemmatizer
from nltk.tokenize import word_tokenize
from nltk.stem import PorterStemmer
           lemmatizer = WordNetLemmatizer()
stemmer = PorterStemmer()
           1 = len(cleaned_tokens)
for i in range(1):
Json
              r i in range(1):
    elment_len = len(cleaned_tokens[i])
            for w in range(elment_len):
    cleaned_tokens[i][w] = (stemmer.stem(cleaned_tokens[i][w]))
# cleaned_tokens
ىلت
                                                                                                                            Python
       lemmatizing tokens
   H 🕢 🥫 📭 🔽 🧿 📢
                                                                                      ╆ 18°C Mostly cloudy 🔨 🥻 Ϥͽ) 🗯 🔗 📰 is 11:45 گ۰۰۰ 🛼
   File Edit Selection View Go Run Terminal Help
                                                                                                           lemmatizing tokens
           from nltk.stem import WordNetLemmatizer
           lemmatizer = WordNetLemmatizer()
           Json
           tokens_len = len(cleaned_tokens)
for i in range(tokens_len):
    cleaned_tokens[i] = [item for item in cleaned_tokens[i] if len(item)>3]
    Pvthon
Python
     ... print some tokens:
         [['riddler', 'sadist', 'serial', 'killer', 'begin', 'murder', 'polit', 'figur', 'gotham', 'batman', 'forc', 'investig', 'citi', 'hidden', 'corrupt',
                                                                                     H 🥝 🔚 🖐 🔽 🧑 刘
\blacksquare
```

تخصيص ليبل:



در مرحله بعد، برای هر استوری لاین یک وکتور از کلمات ساختم که در آن تعداد دفعات تکرار کلمات هم نشان داده میشود. اندازه وکتور را نرمال سازی کردم که به یک برسد. ساخت وکتور:

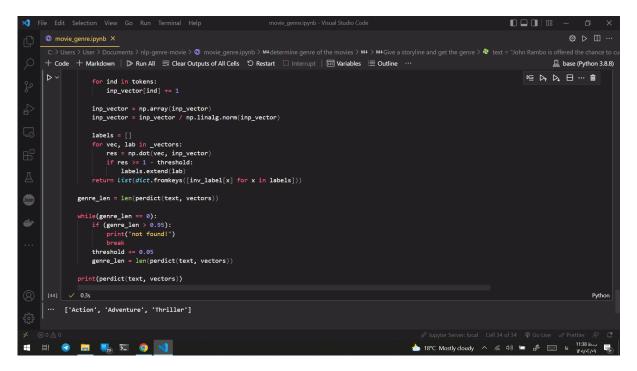
در مرحله بعد، یک استوری لاین از یک فیلم، که در فایل dataset نداریم، به عنوان نمونه دادم. همان مراحلی که برای استوری لاین های قبلی انجام دادم، برای این استوری لاین جدید تکرار کردم و وکتور ساختم. سپس زاویه وکتورها را بررسی کردم و با استفاده از کسینوس زاویه بین آنها، ژانرهای نزدیک به آن را پیدا کردم و در خروجی چاپ کردم.

```
process langueges on imdb movies > M±normalize data > M±labelling genres > 🐠 dim_words = len(dict_words).dim_level + Markdown | ⊳ Run All 🗮 Clear Outputs of All Cells 🔊 Restart 🗆 Interrupt | 📼 Variables 🗏 Outline ···
                                                                                                                                                                                                Labase (Python 3.8.8)
              text = "John Rambo is offered the chance to cut short his prison tenure by going on a secret mission for the US government deep into the jungles of
              threshold = 0.15
                   tokens = remove_stopwords(_text.lower())
                   tokens = [dict_words.get(x) for x in extend_story(tokens)]
tokens = [x for x in tokens if x]
print("tokens" + tokens[0])
                   inp_vector = [0] * dim_words
                         inp_vector[ind] += 1
                   inp_vector = np.array(inp_vector)
inp_vector = inp_vector / np.linalg.norm(inp_vector)
                   labels = []
                         vec, lab in _vectors:
res = np.dot(vec, inp_vector)
                         if res >= 1 - threshold:
    labels.extend(lab)
                      eturn List(dict.fromkeys([inv_label[x] for x in labels]))
              genre_len = len(perdict(text, vectors))
H 🕢 📙 🖶 🖂 🜖
                                                                                                                                           🃤 18°C Mostly cloudy 🔨 🦟 طا 11:51 الله 11:54 📥 🕹 📑 اله 11:54 الم
```

برای مثال استوری لاین فیلم Rambo را قرار دادم. با سرچ در گوگل برای فیلم Rambo، استوری لاین زیر را آورد:

Having long-since abandoned his life as a lethal soldier, John Rambo (Sylvester Stallone) lives a solitary life near the Thai border. Two weeks after guiding a missionary (Julie Benz) and her comrades into Burma, he gets an urgent call for help. The missionaries have not returned and although he is reluctant to embrace violence again, Rambo sets out to rescue the captives from the Burmese army.

در کدم این استوری لاین را قرار دادم و ژانر فیلم را به شکل زیر در خروجی چاپ کرد:



به عنوان یک نمونه دیگر، سریال برکینک بد را امتحان کردم:

storyline: Set in Albuquerque, New Mexico, between 2008 and 2010, Breaking Bad follows Walter White, a meek high school chemistry teacher who transforms into a ruthless player in the local methamphetamine drug trade, driven by a desire to financially provide for his family after being diagnosed with terminal lung cancer خروجی:

```
M4 Give a storyline and get the genre > № text = "John Rambo is offered the chance to cut short his prison tenure by going on a secret missi + Code + Markdown | ▶ Run All 

Code + Markd
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         ■ base (Python 3.8.8)
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          for ind in tokens:
   inp_vector[ind] += 1
                                                               inp_vector = np.array(inp_vector)
inp_vector = inp_vector / np.linalg.norm(inp_vector)
                                                                    for vec, lab in _vectors:
    res = np.dot(vec, inp_vector)
    if res >= 1 - threshold:
                                                                labels.extend(lab)
return List(dict.fromkeys([inv_label[x] for x in labels]))
                                               genre_len = len(perdict(text, vectors))
                                               while(genre_len == 0):
    if (genre_len > 0.95):
        print("not found!")
        break
                                                                threshold += 0.05
                                                                 genre len = len(perdict(text, vectors))
                                              print(perdict(text, vectors))
          ··· ['Drama', 'Thriller']
H 🥝 🤚 📭 🔽 🧿 刘
```

در ادامه لینک صفحاتی که از آنها دیتا جمعآوری کردم را قرار میدهم:

- 1. https://www.imdb.com/chart/top/?ref_=nv_mv_250
- 2. https://www.imdb.com/chart/boxoffice
- 3. https://www.imdb.com/chart/moviemeter
- 4. https://www.imdb.com/chart/tvmeter
- 5. https://www.imdb.com/chart/toptv
- 6. https://www.imdb.com/india/top-rated-indian-movies
- 7. https://www.imdb.com/chart/bottom
- 8. https://www.imdb.com/search/title/?genres=action
- 9. https://www.imdb.com/search/title/?genres=adventure
- 10. https://www.imdb.com/search/title/?genres=biography
- 11. https://www.imdb.com/search/title/?genres=crime
- 12. https://www.imdb.com/search/title/?genres=comedy
- 13. https://www.imdb.com/search/title/?genres=documentary
- 14. https://www.imdb.com/search/title/?genres=drama
- 15. https://www.imdb.com/search/title/?genres=family
- 16. https://www.imdb.com/search/title/?genres=fantasy
- 17. https://www.imdb.com/search/title/?genres=history
- 18. https://www.imdb.com/search/title/?genres=mystery
- 19. https://www.imdb.com/search/title/?genres=horror
- 20. https://www.imdb.com/search/title/?genres=sci-fi
- 21. https://www.imdb.com/search/title/?genres=documentary
- 22. https://www.imdb.com/search/title/?genres=war
- 23. https://www.imdb.com/search/title/?genres=thriller
- 24. https://www.imdb.com/search/title/?genres=war
- 25. https://www.imdb.com/search/title/?genres=western